Opis problemu

Klasyfikacja grafowych reprezentacji ręcznie rysowanych cyfr na gotowym zbiorze danych SuperpixelsMNIST.

Architektura sieci

```
self.conv1 = SplineConv(d.num_features, 32, dim=2, kernel_size=5)
self.conv2 = SplineConv(32, 64, dim=2, kernel_size=5)
self.fc1 = torch.nn.Linear(64, 128)
self.fc2 = torch.nn.Linear(128, d.num_classes)
```

Opis ustawień wpływających na naukę sieci

Funkcja straty jest funkcją, która odwzorowuje zdarzenie lub wartości jednej lub więcej zmiennych na liczbę rzeczywistą, intuicyjnie reprezentującą pewien "koszt" związany z tym zdarzeniem. Tutaj wykorzystana została **funkcja entropii krzyżowej**.
Optymalizator to algorytm używana do zmiany atrybutów sieci neuronowej (takich jak np.: wagi) w celu zmniejszenia strat, tym samym zwiększenia skuteczności sieci. Tutaj wykorzystano optymalizator **Adam**, który jest rozszerzeniem stochastycznego zejścia gradientowego (SGD).
Kryterium stopu nauki to pojęcie odnoszące się do zatrzymania procesu nauczania, aby zmaksymalizować efektywność sieci. Trenowanie należy przerwać, gdy wartości funkcji straty na zbiorze treningowym zaczynają się spłaszczać.
Współczynnik uczenia to parametr o małej wartości używany przy trenowaniu sieci neuronowych. Współczynnik uczenia kontroluje, jak szybko model jest dostosowywany do problemu.
Wielkość partii odnosi się do liczby przykładów treningowych używanych w jednej iteracji. Wartość ta waha się od 1 (sieć jest aktualizowania po każdej próbce) aż do wielkości zestawu treningowego.
Epoki to parametr, który określa, ile razy algorytm uczenia będzie pracował przez cały zestaw danych treningowych.

Wykres prezentujący zmiany błędu

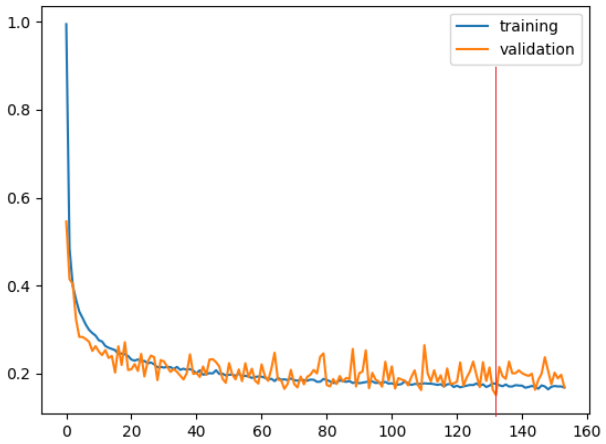

Charakterystyka nauki

Sprzęt: Intel i7 12 rdzeni, 32GB RAM, RTX Quadro 5000
Czas nauki: ok. 85 min

Skuteczność w literaturze

97.40% - Lovasz Convolutional Network (LCNs)
(Yadav, Prateek, et al. "Lovasz convolutional networks." The 22nd International Conference on Artificial Intelligence and Statistics. PMLR, 2019.)

Skuteczność

95.56 % - zbiór treningowy

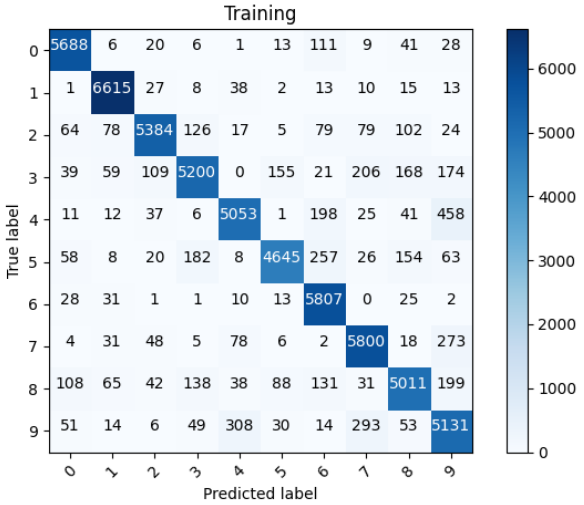

Skuteczność

90.37 % - zbiór testowy

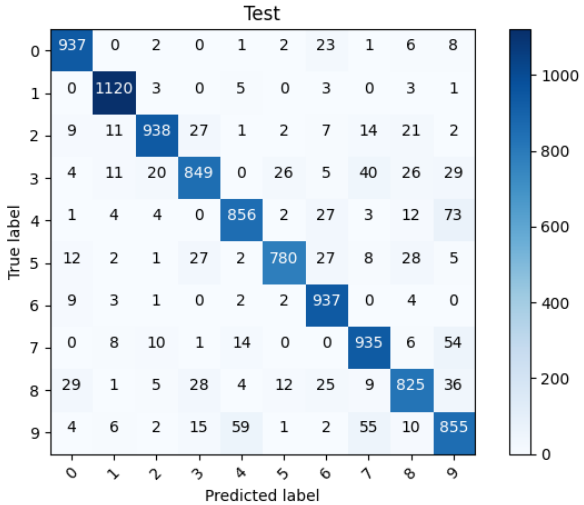

Przykładowa wizualizacja danych wejściowych

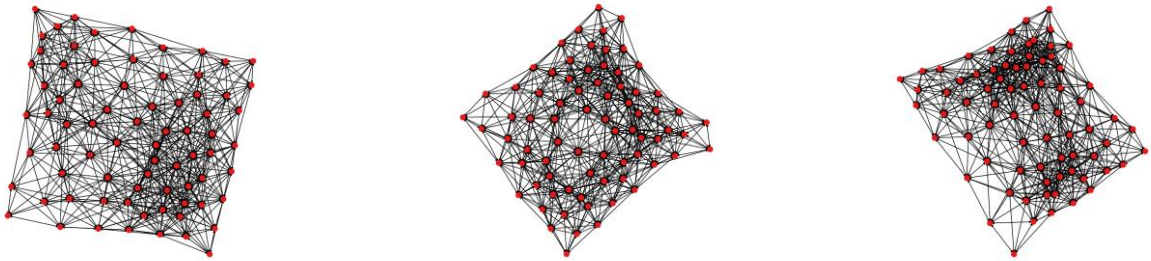

Opis problemu

Klasyfikacja grafowych reprezentacji ręcznie rysowanych cyfr na gotowym zbiorze danych SuperpixelsMNIST. **Tutaj architektura sieci została zmieniona.**

Architektura sieci

```
self.conv1 = SplineConv(d.num_features, 64, dim=2, kernel_size=3)
self.conv2 = SplineConv(64, 128, dim=2, kernel_size=3)
self.fc1 = torch.nn.Linear(128, 256)
self.fc2 = torch.nn.Linear(256, d.num_classes)
```

Opis ustawień wpływających na naukę sieci

Funkcja straty jest funkcją, która odwzorowuje zdarzenie lub wartości jednej lub więcej zmiennych na liczbę rzeczywistą, intuicyjnie reprezentującą pewien "koszt" związany z tym zdarzeniem. Tutaj wykorzystana została **funkcja entropii krzyżowej**.
Optymalizator to algorytm używana do zmiany atrybutów sieci neuronowej (takich jak np.: wagi) w celu zmniejszenia strat, tym samym zwiększenia skuteczności sieci. Tutaj wykorzystano optymalizator **Adam**, który jest rozszerzeniem stochastycznego zejścia gradientowego (SGD).
Kryterium stopu nauki to pojęcie odnoszące się do zatrzymania procesu nauczania, aby zmaksymalizować efektywność sieci. Trenowanie należy przerwać, gdy wartości funkcji straty na zbiorze treningowym zaczynają się spłaszczać.
Współczynnik uczenia to parametr o małej wartości używany przy trenowaniu sieci neuronowych. Współczynnik uczenia kontroluje, jak szybko model jest dostosowywany do problemu.
Wielkość partii odnosi się do liczby przykładów treningowych używanych w jednej iteracji. Wartość ta waha się od 1 (sieć jest aktualizowania po każdej próbce) aż do wielkości zestawu treningowego.
Epoki to parametr, który określa, ile razy algorytm uczenia będzie pracował przez cały zestaw danych treningowych.

Wykres prezentujący zmiany błędu

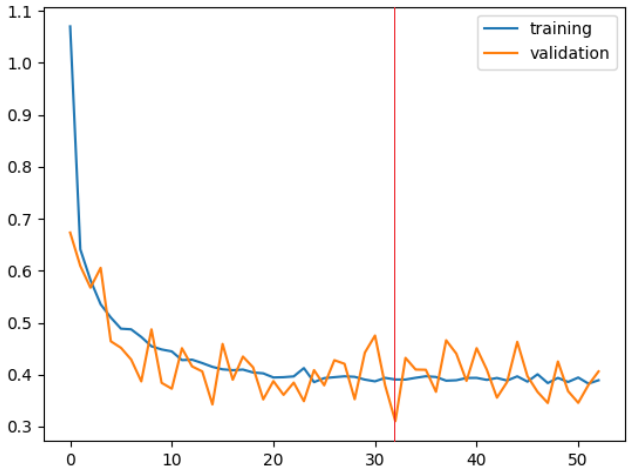

Charakterystyka nauki

Sprzęt: Intel i7 12 rdzeni, 32GB RAM, RTX Quadro 5000
Czas nauki: ok. 30 min

Skuteczność w literaturze

97.40% - Lovasz Convolutional Network (LCNs)
(Yadav, Prateek, et al. "Lovasz convolutional networks." The 22nd International Conference on Artificial Intelligence and Statistics. PMLR, 2019.)

Skuteczność

96.51% - zbiór treningowy

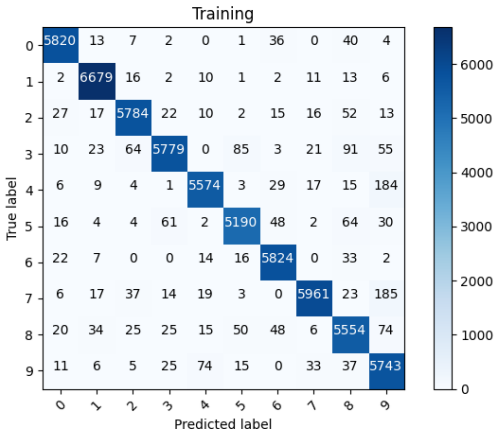

Skuteczność

96.22% - zbiór testowy

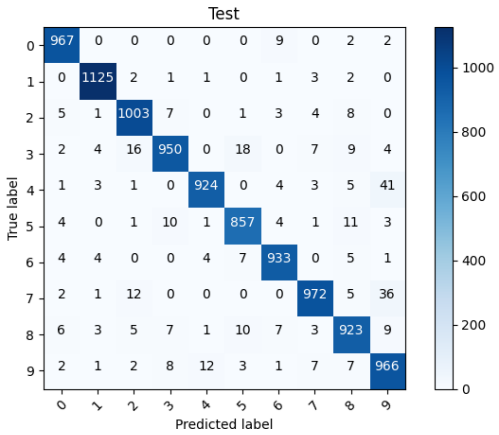

Przykładowa wizualizacja danych wejściowych

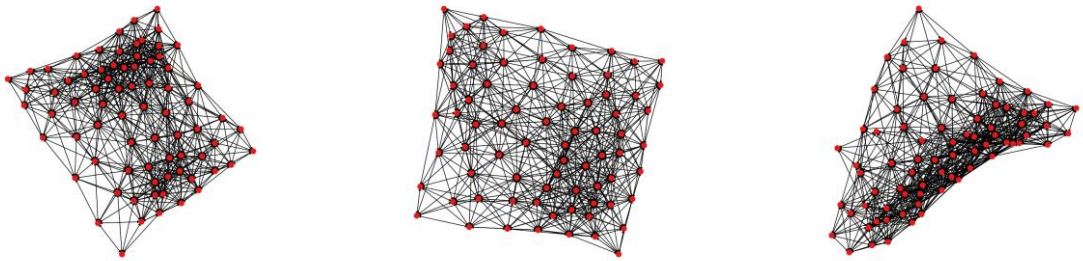

Opis problemu

Rozwiązanie problemu klasyfikacji obiektów ze zbioru Cora, będącego podzbiorem zbioru Planetoid.

Architektura sieci

```
self.conv1 = SplineConv(d.num_features, 16, dim=1, kernel_size=2)
self.conv2 = SplineConv(16, d.num_classes, dim=1, kernel_size=2)
```

Opis ustawień wpływających na naukę sieci

Funkcja straty jest funkcją, która odwzorowuje zdarzenie lub wartości jednej lub więcej zmiennych na liczbę rzeczywistą, intuicyjnie reprezentującą pewien "koszt" związany z tym zdarzeniem. Tutaj wykorzystana została **funkcja entropii krzyżowej**.
Optymalizator to algorytm używana do zmiany atrybutów sieci neuronowej (takich jak np.: wagi) w celu zmniejszenia strat, tym samym zwiększenia skuteczności sieci. Tutaj wykorzystano optymalizator **Adam**, który jest rozszerzeniem stochastycznego zejścia gradientowego (SGD).
Kryterium stopu nauki to pojęcie odnoszące się do zatrzymania procesu nauczania, aby zmaksymalizować efektywność sieci. Trenowanie należy przerwać, gdy wartości funkcji straty na zbiorze treningowym zaczynają się spłaszczać.
Współczynnik uczenia to parametr o małej wartości używany przy trenowaniu sieci neuronowych. Współczynnik uczenia kontroluje, jak szybko model jest dostosowywany do problemu.
Wielkość partii odnosi się do liczby przykładów treningowych używanych w jednej iteracji. Wartość ta waha się od 1 (sieć jest aktualizowania po każdej próbce) aż do wielkości zestawu treningowego.
Epoki to parametr, który określa, ile razy algorytm uczenia będzie pracował przez cały zestaw danych treningowych.

Wykres prezentujący zmiany błędu

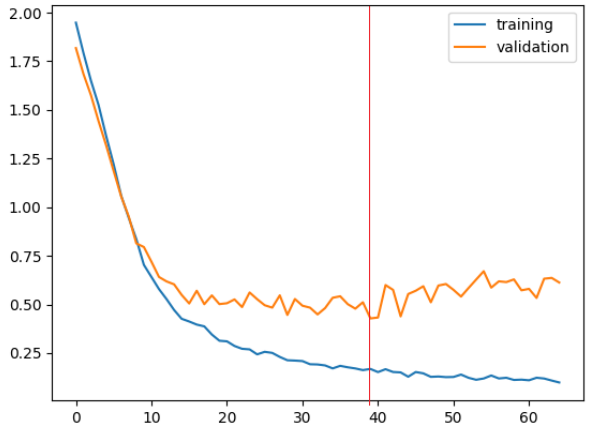

Charakterystyka nauki

Sprzęt: Intel i7 12 rdzeni, 32GB RAM, RTX Quadro 5000
Czas nauki: ok. 2 min

Skuteczność w literaturze

82.60% - Lovasz Convolutional Network (LCNs)
(Yadav, Prateek, et al. "Lovasz convolutional networks." The 22nd International Conference on Artificial Intelligence and Statistics. PMLR, 2019.)

Skuteczność

91.69% - zbiór treningowy

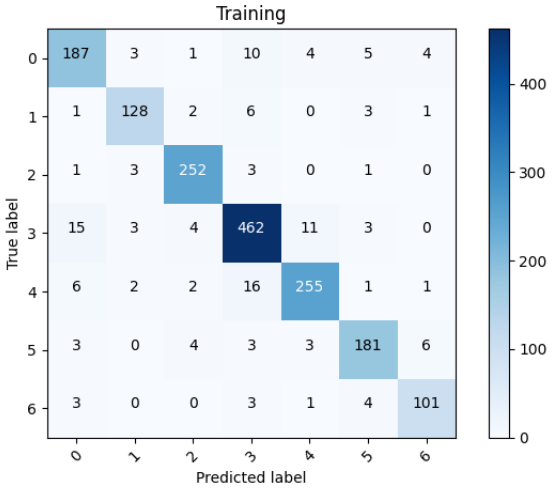

Skuteczność

92.60% - zbiór testowy

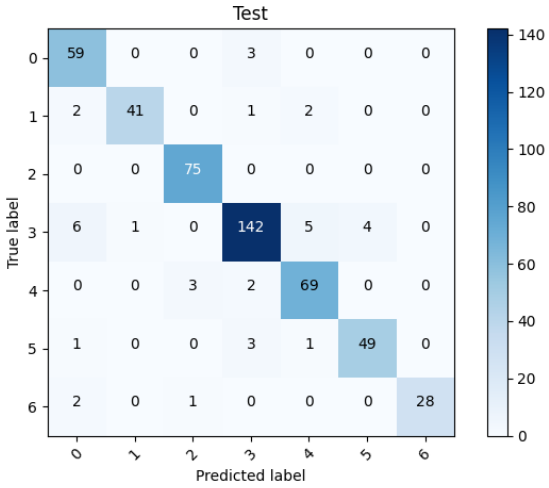

Przykładowa wizualizacja danych wejściowych

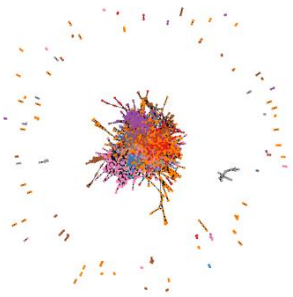

Opis problemu

Rozwiązanie problemu klasyfikacji obiektów ze zbioru Cora, będącego podzbiorem zbioru Planetoid. **Tutaj architektura sieci została zmieniona.**

Architektura sieci

```
self.conv1 = SplineConv(d.num_features, 32, dim=1, kernel_size=4)
self.conv2 = SplineConv(32, d.num_classes, dim=1, kernel_size=4)
```

Opis ustawień wpływających na naukę sieci

Funkcja straty jest funkcją, która odwzorowuje zdarzenie lub wartości jednej lub więcej zmiennych na liczbę rzeczywistą, intuicyjnie reprezentującą pewien "koszt" związany z tym zdarzeniem. Tutaj wykorzystana została **funkcja entropii krzyżowej**.
Optymalizator to algorytm używana do zmiany atrybutów sieci neuronowej (takich jak np.: wagi) w celu zmniejszenia strat, tym samym zwiększenia skuteczności sieci. Tutaj wykorzystano optymalizator **Adam**, który jest rozszerzeniem stochastycznego zejścia gradientowego (SGD).
Kryterium stopu nauki to pojęcie odnoszące się do zatrzymania procesu nauczania, aby zmaksymalizować efektywność sieci. Trenowanie należy przerwać, gdy wartości funkcji straty na zbiorze treningowym zaczynają się spłaszczać.
Współczynnik uczenia to parametr o małej wartości używany przy trenowaniu sieci neuronowych. Współczynnik uczenia kontroluje, jak szybko model jest dostosowywany do problemu.
Wielkość partii odnosi się do liczby przykładów treningowych używanych w jednej iteracji. Wartość ta waha się od 1 (sieć jest aktualizowania po każdej próbce) aż do wielkości zestawu treningowego.
Epoki to parametr, który określa, ile razy algorytm uczenia będzie pracował przez cały zestaw danych treningowych.

Wykres prezentujący zmiany błędu

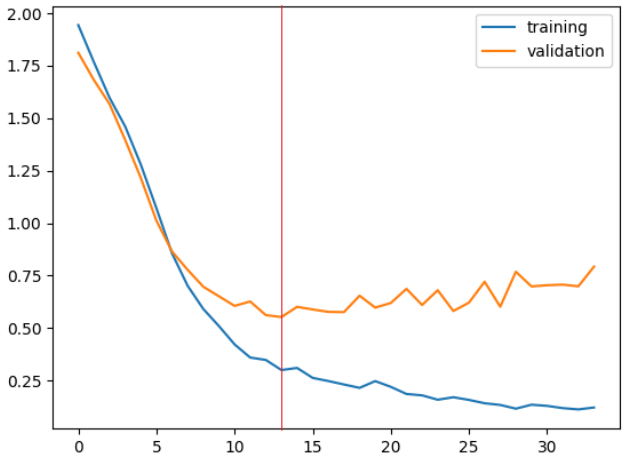

Charakterystyka nauki

Sprzęt: Intel i7 12 rdzeni, 32GB RAM, RTX Quadro 5000
Czas nauki: ok. 1 min

Skuteczność w literaturze

82.60% - Lovasz Convolutional Network (LCNs)
(Yadav, Prateek, et al. "Lovasz convolutional networks." The 22nd International Conference on Artificial Intelligence and Statistics. PMLR, 2019.)

Skuteczność

87.06% - zbiór treningowy

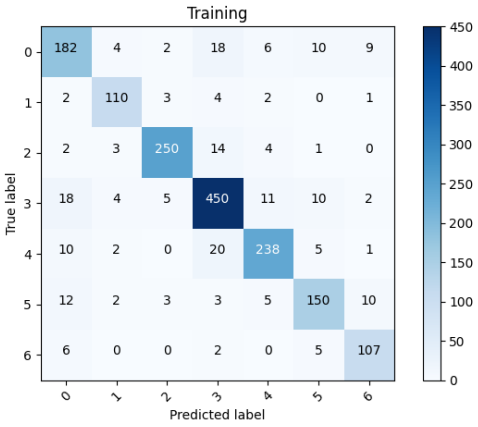

Skuteczność

86.80% - zbiór testowy

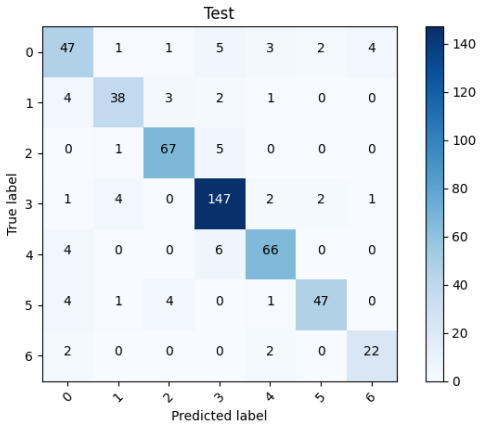

Przykładowa wizualizacja danych wejściowych